

Edging GPT 第三版本研究报告与立项报告

执行摘要与目录

本报告将 **Edge (象) —Edgefield (边界场) —Edging (持续观测与推演)** 作为第一性原则，提出 Edging GPT V3 的完整方案：在理论上，把对象视为处于持续变化场中的时点状态切片，而不是静态人格标签；在技术上，采用“**状态空间模型 + 贝叶斯滤波 + 动态图建模 + 主动采样 + 多路径模拟**”的分层架构；在产品上，把 GPT 从“被动回答器”升级为“**信息采样驱动器与演化解释器**”；在项目管理上，建议以 36 个月、三阶段推进，先做可解释 MVP，再做关系网络与因果校正，最后做企业化与行业化扩展。报告同时给出正式立项文本、预算假设、合规边界、评估方案与优先交付物。该方向的现实性在于：AI 企业应用正在快速普及，但大多数组织仍停留在试点到规模化的过渡阶段；同时，监管对个人信息、生成式 AI 标识和拟人化互动的要求已经显著收紧，这反而有利于建立“高解释性、强采样约束、低风险交互”的长期壁垒。 ¹

目录包括：理论框架；数据与采样策略；算法与系统架构；GPT 目标函数与交互设计；产品化、评估与风险；立项报告附录；下一步可交付物。

理论框架

本报告采用三个项目内生公理。第一，**世界中的人、关系、组织与事件都不是静止对象，而是持续演化过程**。第二，**Edge 不是“你是谁”的标签，而是某一时点的状态切片**。第三，**Edgefield 不是临时拼装出的上下文，而是持续存在、不断受关系、环境、时间和事件影响的变化场**。这种“状态一流一反馈”的构造，与系统动力学对 stock / flow 的理解一致：动态系统由可积累的状态量和改变状态的流率组成；同时，现代状态空间模型正是用“观测方程 + 状态转移方程”来表达可观测变量与潜在状态之间的关系。 ²

在形式化上，可定义 64 个变化基向量 $B = \{b_1, \dots, b_{64}\}$ ，并将任一时刻的 Edge 记为

$$e_t = \sum_{i=1}^{64} \alpha_{t,i} b_i, \quad \alpha_{t,i} \geq 0, \quad \sum_{i=1}^{64} \alpha_{t,i} = 1.$$

这里的 $\alpha_{t,i}$ 不是“属于某卦的概率”，而是该对象在 64 种变化规律上的**投影权重**。因此，64 维表示不是分类器，而是**连续表示空间**。如果工程上不强制 simplex 约束，也可以先学习非约束向量 $\tilde{e}_t \in \mathbb{R}^{64}$ ，再做 $e_t = \text{softmax}(\tilde{e}_t)$ 归一化，以便兼容对数几率、稀疏编码或变分推断。采用这种潜变量表示，和状态空间建模、矩阵分解、NMF、VI 等方法的基本思想是兼容的：前者提供时序演化，后者提供低维或稀疏可解释表示。 ³

Edgefield 可定义为

$$F_t = \langle e_t, A_t, x_t, m_t, \Sigma_t \rangle.$$

其中， e_t 为当前 Edge， A_t 为关系网络或 Edge Map 的邻接结构， x_t 为外部环境向量， m_t 为历史记忆或长期偏置， Σ_t 为当前不确定性。这个定义的关键不是“拼凑更多特征”，而是承认对象的演化始终发生在**关系依赖与环境扰动共同作用**之中。GNN 文献之所以重要，不在于“套一个热门模型”，而在于它把节点间依赖视为消息传递问题；动态 GNN 的意义，则在于现实中的网络拓扑和节点属性都是随时间变化的。因果推断文献进一步提醒我们：观察、干预与反事实属于不同层级，真正能支撑“下一步 Edge Probe 是否有效”的，不是相关性而是可识别的因果结构。 ⁴

基于上述定义，若以 $C \in \mathbb{R}^{64 \times 64}$ 表示“变化规律冲突矩阵”，则可定义 **Edge Tension** 为

$$\tau_t = e_t^\top C e_t.$$

它衡量当前状态中“互相拉扯”的强度；例如推进与抽离、表达与保留、控制与释放等。若以 W_p, U_p, V_p 为可学习参数，可定义 **Edge Potential** 为

$$p_t = \sigma(W_p e_t + U_p x_t + V_p \phi(A_t)),$$

它表示系统向若干方向继续演化的势能分布。这里 $\phi(A_t)$ 可以是图嵌入、邻居聚合或动态图摘要。于是，**象变** 即 **Edge Shift** 可表示为

$$\Delta e_t = e_t - e_{t-1},$$

而 **Edge Trajectory** 则是历史轨迹

$$\mathcal{T}_{0:T} = (e_0, e_1, \dots, e_T).$$

当对象不止一个时，Edge Map 记为

$$G_t = (V_t, E_t, X_t), \quad X_t \in \mathbb{R}^{|V_t| \times 64},$$

其中每个节点都有自己的 Edge Vector，每条边有关系类型、强度、方向和时间戳。 5

为了让 GPT 真正“有驱动”，还需要定义 **信息势差**。设潜在状态后验为 $q(z_t | D_{\leq t})$ ，则当前不确定性可写为

$$\mathcal{I}_t = H[q(z_t | D_{\leq t})].$$

任一候选问题 q 的价值可定义为

$$\text{EIG}(q) = \mathbb{E}_{a \sim p(a|q, D_t)} [H(z_t | D_t) - H(z_t | D_t, q, a)].$$

于是主动提问不再是“多聊几句”，而是求解

$$q_t^* = \arg \max_q \left(\text{EIG}(q) - \lambda \text{Cost}(q) - \rho \text{Risk}(q) - \kappa \text{Intrusive}(q) \right).$$

这与主动特征获取、贝叶斯实验设计和新近的 BED-LLM 方向高度一致：核心都是在**信息增益**、**采样成本**和**风险**之间做最优平衡。 6

在演化方程上，建议采用“项目自定义语义层 + 经典动力学后端”的双层结构。推荐的 MVP 方程为

$$z_t = A z_{t-1} + B u_t + \Gamma x_t + \epsilon_t, \quad y_t = H z_t + \nu_t, \quad e_t = \text{softmax}(W z_t),$$

其中 u_t 代表用户行为、对话事件、外部冲击， y_t 为观察值。若处理多对象网络，则对每个节点 i 用

$$z_{i,t} = f_\theta \left(z_{i,t-1}, x_{i,t}, \sum_j A_{ij,t} g_\theta(z_{j,t-1}) \right) + \epsilon_{i,t}.$$

若做分支模拟，可采用条件马尔可夫近似


$$P(e_{t+1} | e_t, x_t, A_t),$$

或连续时间随机扰动模型

$$\frac{de_t}{dt} = f_\theta(e_t, x_t, A_t) + \sigma \eta_t.$$

这些选项并不互斥：状态空间模型适合 MVP 的可解释递归估计，动态 GNN 适合关系网络，因果模型适合干预评估，随机扰动项则用来表达现实世界中不可完全观测的不确定性。⁷

下面给出 Edgefield 演化示意图。这里没有“重建场”的概念，只有**初始 Edge**、**连续 Edge Shift**与**轨迹累积**。



如需可视化输出，建议优先生成四类图像：**64 维 Edge 雷达图**、**Edge Shift 瀑布图**、**Edge Trajectory 时序图**、**Edge Map 关系网络图**。若做企业版，还可生成“组织事件—关系张力—演化路径”的桑基图或因果图。

建议优先检索的参考文献类型是：中文综述与教材用于概念统一，系统动力学和状态空间模型经典教材用于演化方程，图神经网络与动态 GNN 的近三年综述用于关系网络，因果推断综述与 Pearl 体系用于干预设计，贝叶斯滤波与变分推断综述用于后验估计，主动特征获取与 BED-LLM 类论文用于采样策略。⁸

数据与采样策略

Edging GPT V3 的数据观应当从“一次性问卷”转向“**多源、分层、可中断、可审计采样**”。这与主动特征获取研究的结论一致：高成本场景下，最优策略通常不是收集所有特征，而是按实例逐步获取最有信息量的数据；而在生成式 AI 交互中，顺序式贝叶斯实验设计可以显著提升信息收集效率。⁶

在源头上，建议将数据分成六类：**Edge Test 问卷**、**对话侧写**、**环境侧写**、**关系侧写**、**时间序列采样**、**外部数据**。其中，问卷负责给出首个结构化 Initial Edge；对话侧写负责在低摩擦情况下持续补全；环境与关系侧写负责解释 Edgefield 背景；时间序列负责沉淀轨迹；外部数据负责识别组织、行业、舆情和地理事件对 Edgefield 的冲击。基于数据采集成本与隐私约束，MVP 阶段应优先使用问卷、对话、用户主动输入的关系信息与公开新闻事件，谨慎处理位置、联系人、第三方资料等高风险来源。⁹

数据源	主要用途	典型信噪比	可获取性	隐私风险	建议频率	优先级
Edge Test 问卷	初始化 64 维 Edge Vector	高	高	中	首次 + 季度复测	P0
对话侧写	实时降低信息势差	中高	高	中高	每轮对话事件触发	P0
环境侧写	捕捉组织/家庭/行业冲击	中	中	中	周级或事件触发	P1
关系侧写	构造 Edge Map、关系张力	中高	中	高	关系变化时采样	P1
时间序列采样	形成 Edge Trajectory	高	中高	中	周/月固定回访	P0
外部数据	校准环境向量 x_t	中	中	低到高等不等	日级抓取或事件触发	P1
位置与设备数据	丰富上下文，但价值有限	低中	低中	高	默认关闭，仅可选	P2
第三方社交/通讯录	理论上可增强 Edge Map	中	低	极高	原则上不接入	禁限

这里的“信噪比”是产品层面的估计，不是统计意义上的固定常数。一般而言，**结构化问卷的信息密度最高、解释成本最低**；对话数据覆盖广，但模糊性高；关系信息对 Edge Map 非常关键，但合规成本也最高；外部公开事件对环境向量很有帮助，但需做时效与可信源筛选。¹⁰

建议采样节奏采用三级机制。**首次初始化**：完成 48–64 题 Edge Test，并采 3–5 个环境与关系关键变量，形成 Initial Edge。**事件驱动采样**：当用户提及冲突升级、岗位变化、关系断裂、团队调整、健康事件等触发词时，GPT 进入侧写模式。**节律性复测**：轻量版每周 3–5 题、月度 12–16 题、季度完整复测一次，以减小回忆偏差并持续校正 Edge Trajectory。若企业版接入公开新闻或组织公告，可在事件发生时触发环境更新。主动采样的停止条件建议设为：后验熵低于阈值、连续两个问题的增益低于阈值，或用户摩擦评分超过阈值。¹¹

建议的数据结构如下。它既要支持时序建模，也要支持解释与审计。

```
{
  "user_id": "U123",
  "timestamp": "2026-07-06T10:30:00+09:00",
  "edge_vector": [0.03, 0.01, "...64d..."],
  "edge_potential": {"relation_repair": 0.72, "conflict_escalation": 0.41},
  "edge_tension": 0.58,
  "uncertainty": 0.27,
  "environment_vector": {"org_change": 1, "team_pressure": 0.8, "public_event": 0.2},
  "edge_map_delta": [{"target": "manager", "weight": 0.61, "sign": "negative"}],
  "observation_source": ["survey", "dialogue", "manual_relation_input"],
  "consent_flags": {
    "dialogue_profiling": true,
    "relationship_inference": true,
    "external_news_linking": true,
    "location": false
  }
}
```

```

},
"retention_policy": {"chat_days": 180, "feature_days": 365}
}

```

标签体系建议分为四层。第一层是 **状态标签**，例如工作压力、关系温差、表达阈值、控制释放速度等。第二层是 **事件标签**，如岗位调整、公开冲突、冷处理、和解尝试、组织重组。第三层是 **结果标签**，如 7 天内关系改善、30 天内团队离职、14 天内情绪波动缩小。第四层是 **干预标签**，即某个 Edge Probe 是否执行、何时执行、主观接受度与客观效果。这样才能支持后续的因果分析与策略学习。 ¹²

此处的合规边界必须写清。根据《个人信息保护法》，个人信息处理应遵循合法、正当、必要、最小化和透明原则；分析、评估自然人的行为本身就在法域覆盖范围内。对敏感个人信息，需要单独同意，并在存在自动化决策、处理敏感信息、向境外提供信息等情形时进行个人信息保护影响评估。对生成式 AI 服务，还必须保护用户输入与使用记录，不得非法留存可识别身份的输入信息和使用记录，并提高生成内容的准确性和可靠性。

¹³

如果服务面向公众提供，生成内容还需要满足《人工智能生成合成内容标识办法》的显式与隐式标识要求；若产品采用拟人化互动形态，还应提示用户正在与 AI 而非自然人交互，并对过度依赖、沉迷、情感操纵进行风险防控。拟人化互动新规还明确要求服务者具备情感边界引导、心理健康保护、过度依赖风险预警等能力，并禁止把替代社会交往、控制用户心理、诱导沉迷依赖作为服务目标。这对 Edging GPT 的产品设计是硬约束，也是差异化机会：它天然更适合被设计成“观察—实验—反馈”系统，而不是“陪伴型人格替代品”。 ¹⁴

算法与系统架构

在算法选型上，建议采用“一条主干、三类增强”的路线。主干是 **状态空间模型 + 贝叶斯滤波**，因为它最适合做隐状态递归估计、可解释性最好、工程实现稳定；增强模块分别是 **动态图模型**、**因果分析** 与 **采样策略学习**。状态空间模型之所以适合作为基础，是因为它天然区分了测量方程与状态转移方程，能把“用户说了什么”“问卷答了什么”“外部环境发生了什么”与“真正的潜在 Edgefield 状态”分开处理，而卡尔曼滤波及其变体则提供了在线更新机制。 ¹⁵

方法	适合解决的问题	优势	局限	建议阶段
状态空间模型 + 贝叶斯滤波	Edgefield 隐状态估计、时间更新	可解释、递归在线、适合 MVP	线性假设偏强	P0
动力系统 / 微分方程	连续演化与势能分析	理论优雅、可模拟轨迹	参数学习难	P1
动态图神经网络	Edge Map、关系传播、团队网络	捕捉关系依赖与时变结构	数据量要求高	P1
因果推断 / SCM	评估 Edge Probe 是否有效	支持干预与反事实	需要稳定标签和识别假设	P1-P2
变分推断 / 稀疏编码 / NMF	Edge Vector 潜表示估计	维度压缩、可解释表示	需要良好初始化	P0-P1
强化学习	主动提问策略、长期收益最大化	可学个性化采样政策	冷启动难、线上风险高	P2

Edge Vector 的估计建议分三层。**第一层** 是可解释规则初始化：由问卷、人工设计规则和少量校准数据得到初始 e_0 。**第二层** 是表示学习：用 NMF、稀疏编码或概率矩阵分解从历史样本中学习“共现模式”，因为这类方法

天然适合从高维稀疏数据里提取可解释部件表示。**第三层**是后验更新：用变分推断或贝叶斯滤波融合不完整、多噪声、异步到达的数据流。VI 的优势是可把后验估计转化为优化问题，通常比 MCMC 更快，适合在线系统；NMF 的优势是非负与部件化表示，适合解释“变化规律构成”。¹⁶

建议的估计目标可写为

$$\min_{W, H} \|X - WH\|_F^2 + \lambda \|H\|_1 + \gamma \text{Smooth}(H_t, H_{t-1}),$$

其中 X 是由问卷、对话、关系、环境拼成的观察矩阵， WH 为低秩或字典表示， $\|H\|_1$ 鼓励稀疏、提升解释性，Smooth 约束时间相邻状态不要发生不合理跳变。若用变分推断，则令

$$q_\phi(z_t | D_{\leq t}) \approx p_\theta(z_t | D_{\leq t}),$$


并最小化

$$\text{KL}(q_\phi(z_t | D_{\leq t}) \| p_\theta(z_t | D_{\leq t})).$$

这为系统提供了“Edge 值 + 不确定性”双输出，而后者正是主动提问和停问条件的基础。¹⁷

对于 **Edgefield 演变建模**，推荐的 MVP 技术组合如下：用户端到来一个新观察 o_t 后，先进入 Observation Parser，把语言和问卷转换为结构特征；再进入 Edge Filter，以状态空间模型完成潜在状态更新；随后由 Potential Head 输出若干演化势能，由 Tension Head 输出关键张力；最后在 Simulation Engine 中做分支模拟并生成 Edge Probe 建议。若涉及多人关系，用动态图模块对 Edge Map 做邻居传播，再把图摘要送回状态更新层。GNN 在此处并不是替代主干，而是增强边缘。因为关系网络通常是稀疏、异构、时间变化的，动态图 GNN 恰好适合表达“谁影响谁、影响以何种节律传播”。⁵

下面给出建议的系统模块图。



多路径模拟建议采用“有限步长、有限分支”的蒙特卡洛生成。其目标不是宣称“预测未来”，而是输出若干条件性路径：若继续推进、若暂停、若换一种表达、若组织继续波动，会分别出现什么轨迹。由于现实系统存在噪声与参数不确定性，分支模拟比单点预测更符合风险沟通原则。NIST 的生成式 AI 风险框架也强调，生成式系统的风险与生命周期阶段、使用语境、不同 AI Actor 角色密切相关，因此输出应以“路径 + 条件 + 置信区间”而不是“唯一答案”呈现。¹⁸

可采用如下简洁伪代码：

```
Input: 初始观测 D0
Initialize posterior q(z0|D0), Edge e0

for each turn t:
    ot <- parse(user_dialogue, survey_delta, env_event, relation_event)
    q(zt|D<=t) <- BayesianUpdate(q(zt-1|D<=t-1), ot)
    et <- DecodeEdge(q(zt|D<=t))
    It <- Entropy(q(zt|D<=t))

    if It > threshold and user_friction < limit:
        qt <- SelectQuestionBy(EIG - cost - risk - intrusion)
        ask(qt)
    else:
        paths <- Simulate(et, env_t, map_t, horizon=K, branching=B)
        probe <- PlanEdgeProbe(paths, user_risk_budget)
        explain(paths, probe)
```

数据流建议如下表。

模块	输入	输出	说明
Observation Parser	文本、问卷、事件	结构化特征	多源统一编码
Edge Filter	结构特征、历史后验	当前后验、置信区间	递归更新
Edge Decoder	潜状态	64 维 Edge Vector	可解释输出
Edge Map Builder	关系输入、外部事件	图结构 A_t	关系网络
Potential/Tension Head	Edge + 图摘要	势能/张力分数	用于模拟与建议
Simulation Engine	当前状态、外源变量	多路径轨迹	分支模拟
Question Policy	后验不确定性、偏好	下一问	主动采样
GPT Layer	问法、解释模板	自然语言输出	不做主模型，只做人机接口

从实现优先级看，V3 仍不建议一开始就用强化学习直接学整套策略。原因一是冷启动风险大，原因二是交互式策略一旦学偏，容易引发高侵入、高误导或沉迷问题。更稳妥的办法是：MVP 用 EIG + 规则系统；当累计到足够多的“问题—回答—演化结果”三元组后，再训练问题选择策略。Google 关于主动问句改写的工作与主动特征获取研究都指出，序列策略适合用 RL 或 MDP 框架建模，但前提是明确奖励设计与风险约束。¹⁹

GPT目标函数与交互设计

Edging GPT V3 的根本变化，是把 GPT 的目标从“让用户感觉被理解”改为“**在合规和低风险前提下，最大限度降低信息势差，并提升演化预测置信度**”。这与 BED-LLM 提出的大方向一致：LLM 不只是生成答案，也可以在对话中作为顺序式贝叶斯实验设计器，通过最大化预期信息增益来决定下一问。主动特征获取文献也表明，在高成本环境中，问题策略必须同时平衡信息收益与采集成本。²⁰

建议使用以下复合目标函数：

$$\mathcal{J} = \underbrace{\Delta \text{Conf}_{pred}}_{\text{提升预测置信度}} + \beta \underbrace{\text{EIG}(q_t)}_{\text{降低信息势差}} - \underbrace{\lambda \text{Cost}(q_t)}_{\text{用户成本}} - \underbrace{\rho \text{Risk}(q_t)}_{\text{隐私与情绪风险}} - \underbrace{\kappa \text{Friction}(q_t)}_{\text{交互摩擦}}$$

其中 $\Delta \text{Conf}_{pred}$ 可定义为关键路径概率分布的收缩程度， $\text{Risk}(q_t)$ 则综合敏感性、误导可能性、依赖性和触发性。若当前对话对象存在情绪极端、未成年人、长期连续使用等高风险信号，应直接提高 ρ 并切换到保守模式。2026 年中国关于拟人化互动服务的暂行办法已经明确要求服务者具备过度依赖预警、情感边界引导与心理健康保护能力，并禁止将替代社会交往、控制用户心理、诱导沉迷作为服务目标。²¹

主动提问策略建议遵循四条规则。**先问影响大、敏感度低的问题**，例如时间、范围、组织变化、是否普遍发生。**再问关系定位问题**，例如冲突只针对你还是波及多人。**最后才问高敏感个体信息**，例如过去创伤、财务与健康细节，并且默认不问、只在必要时征求同意。**当后验已经足够窄时及时停问**，改为展示多路径与建议实验。这样既符合法律上最小必要原则，也符合用户体验。根据《个人信息保护法》，对敏感个人信息、自动化决策和对个人权益有重大影响的处理，应事前开展个人信息保护影响评估；而《生成式人工智能服务管理暂行办法》要求不得收集非必要个人信息，并要求保护输入与使用记录。²²

最小采样集建议设计为三段式。**第一段：结构定位**，例如“问题开始于什么时候”“是否发生在某一具体事件之后”“是否只在某一关系中出现”。**第二段：环境校准**，例如“最近是否有组织变化、生活阶段变化、第三方压力”。**第三段：干预准备**，例如“你更能接受小步试探、短期暂停，还是直接澄清”。如果用户只想要解释，不想深入测量，则系统应在较高不确定性下输出保守结论，并显式提示“此结论基于受限信息，建议补充 ×× 信息以提升置信度”。这与 NIST AI RMF 对生成式 AI 风险沟通和不同 AI Actor 角色责任的建议一致。¹⁸

以下给出 Prompt 模板。

系统角色：

你是 Edging GPT，不做人格贴标签，不预测命运。

你的任务是：

1. 识别当前 Edge 与 Edgefield 中的不确定区域；
2. 通过最小必要提问降低信息势差；
3. 输出多路径演化，而非单一断言；
4. 推荐低风险、可验证、可回退的 Edge Probe；
5. 当隐私、情绪或依赖风险升高时，自动收缩提问并提示边界。

输入：

- 当前 Edge posterior
- Uncertainty score
- Recent Edge Shift
- Environment vector
- Edge Map summary
- 用户风险预算 (low/medium/high)

输出格式：

- 当前判断
- 缺失信息
- 下一问（若需要）
- 多路径模拟
- Edge Probe
- 置信度与风险提示

下面给出三个代表性场景的对话设计。

场景一：职场关系。

用户说：“我感觉领导突然开始针对我。”

系统不应直接安慰或附和，而应先做低敏感采样：“这种变化大约从什么时候开始？最近团队是否有目标调整、组织变动或绩效压力？这种态度只针对你，还是其他同事也有类似感受？”若确认组织变化与多名成员同时受影响，则环境向量中的“团队压力”权重上升，系统会把“个人被针对”路径的概率下调，把“上游压力传导导致关系温度下降”路径上调，并建议一个低风险 Edge Probe，例如“在一次任务对齐中先澄清目标与优先级，而不是直接对抗其态度”。这种先识别环境冲击、再给出最小实验的模式，更符合可解释与低风险原则。²³

场景二：恋爱冲突。

用户说：“她最近越来越冷淡，我想追问她是不是不爱我了。”

系统先问：“冷淡是最近一周还是更长时间？是否伴随工作、家庭或健康压力？你们的互动是减少了频率，还是减少了情绪表达？”如果没有足够证据指向关系退化，就不应把 Edge Potential 直接推向“关系终止”，而要分出至少三条路径：外部压力导致短期抽离、关系内部边界收缩、长期撤离倾向。推荐的 Edge Probe 可以是“把追问改成一次低压澄清：表达关切但不要求立即回答”，并设置观察窗，比如 72 小时后的回应质量。这避免 GPT 顺着用户情绪走，也减少对对方主观意图的武断归因。对于拟人化互动产品，还必须防止系统把自己变成“替代伴侣”而不是“关系观察器”。²⁴

场景三：团队变动。

用户说：“团队突然变动频繁，我不知道要不要离开。”

系统应先识别是否存在外部冲击：“变动具体是裁员、调岗、负责人更换还是目标重设？影响范围有多大？你手上的关键资源是在上升、下降还是不确定？”之后用 Edge Map 评估用户在网络中的连接位置，用环境向量估计组织不稳定度，再输出多路径：继续留在原位、主动换组、准备外部机会三条轨迹。每条轨迹要给出条件和可验证信号，例如“若未来两周资源进一步下降且关键协作人离开，则路径 B 概率上升”。这类设计更接近“决策辅助系统”，而不是“情绪陪聊”。²⁵

A/B 测试指标建议如下。

指标	定义	目标值方向	说明
信息势差下降率	对话前后熵降降幅	越高越好	核心驱动指标
多路径校准误差	预测路径概率与真实结果偏差	越低越好	评估模拟可信度
最小采样率	达到目标置信度所需问题数	越低越好	控制摩擦
用户风险事件率	被投诉、触发、依赖预警比例	越低越好	合规红线
Edge Probe 执行率	用户采纳建议实验的比例	越高越好	验证可操作性
Probe 成功率	实验后达到预期改善比例	越高越好	产品价值核心
会话完成率	未中途流失的比例	越高越好	体验指标

指标	定义	目标值方向	说明
二次回访率	7/30 日复访比例	越高越好	建模连续性
人工复核一致率	专家与模型判断一致度	越高越好	质量控制

产品化、评估与风险

从现实商业环境看，AI 企业采用率正在上升，但大量组织仍停留在试点和局部价值阶段。McKinsey 2025 年调查显示，近九成受访组织已经在至少一个业务功能中使用 AI，但大多数尚未实现企业级规模化；工作流重构、领导层推动、明确 KPI 和人机校验流程，是高绩效组织与普通组织的关键差别。Stanford AI Index 2025 也显示，2024 年有 78% 的组织报告正在使用 AI，AI 业务使用明显加速。对 Edging GPT 而言，这意味着企业版和 SaaS 版有现实窗口，但必须从“具体问题价值”切入，而不是停留在概念层。²⁶

MVP 功能建议控制在六项：**Initial Edge 测试、对话中的主动采样、当前 Edge 解释、多路径模拟、Edge Probe 建议、历史轨迹回看**。企业版 MLP 再增加 **团队 Edge Map、环境事件对齐、管理者仪表盘、风险预警、合规审计日志**。商业模式上，面向个人可做订阅制深度报告；面向中小团队可做按席位 SaaS；面向大型企业可做私有化部署、咨询与培训；面向研究机构和咨询方可做脱敏后的方法授权与工具授权，但**不建议出售原始个人级数据**，这在合规与品牌上都代价过高。²⁷

三阶段路线图建议如下。

阶段	时间	目标	核心交付	主要风险
第一阶段	0–6 月	跑通 MVP	64 维 Edge Test、主动提问、基本模拟、边界实验闭环	理论漂移、采样过重
第二阶段	6–18 月	提升网络与因果能力	Edge Map、动态关系建模、A/B 框架、专家校验库	标签质量、关系隐私
第三阶段	18–36 月	企业化与行业化	团队版、私有化部署、行业模板、策略学习	交付复杂、销售周期长

预算与人力建议按“开放区间”写入。以下预算假设以中国一线/新一线城市、混合办公、18–36 个月研发为基础，不含大规模市场投放。若使用昂贵闭源模型 API，成本需上浮。

角色	第一阶段 FTE	第二阶段 FTE	第三阶段 FTE	主要职责
产品负责人	1	1	1	路线、需求、实验
理论/研究负责人	1	1	1	Edge 理论、指标、白皮书
算法工程师	2	4	5	过滤、图模型、模拟
LLM/应用工程师	2	3	3	交互、Prompt、Agent
后端/数据工程师	2	3	4	数据管道、日志、权限
前端/设计	1	2	2	产品体验与可视化
合规/法务/安全	0.5	1	1	审计、隐私、备案

角色	第一阶段 FTE	第二阶段 FTE	第三阶段 FTE	主要职责
行业顾问/心理与组织专家	0.5	1	2	标注、校验、应用模版
	阶段	预计周期	预算估算	预算说明
	第一阶段	6 个月	180–260 万元	MVP、人机评估、合规框架
	第二阶段	12 个月	420–650 万元	动态图、A/B、企业试点
	第三阶段	18 个月	900–1500 万元	私有化、行业模板、商业化

验证方案必须分成离线与在线两层。**离线回测**：用历史轨迹数据验证“给定 e_t, x_t, A_t 是否能更准确地预测 $e_{t+\Delta}$ ”；同时回测不同问题策略对后验熵下降的效率。**在线实验**：随机将用户分配到静态问卷组、规则追问组、EIG 策略组，对比其信息势差下降率、会话完成率、Probe 执行率和 7/30 日复访率。对企业版，还要追踪团队层面的“冲突解决率、人员流失预警提前量、管理者决策修正率”。主动特征获取研究表明，衡量系统优劣时不能只看预测准确率，还必须计算采样成本与误分类成本；这与 Edging 的目标高度一致。 28

评估指标表建议如下。

类别	指标	计算方式
状态预测	变化预测准确率	$\text{Acc}(e_{t+\Delta})$ 或 Top-k path hit
演化校准	置信度校准误差	ECE / Brier score
行为改变	用户行为改变率	执行 Edge Probe 的用户占比
实验效果	Probe 成功率	执行后达到预设改变变量的比例
用户价值	留存率	D7 / D30 Retention
商业效果	付费转化率	免费到订阅/企业试点转化
风险控制	不当建议率	被人工复核判定高风险的输出比例
数据质量	标注一致率	Cohen’ s Kappa / Krippendorff Alpha

数据标注建议采用“双轨制”。一轨是**结构标签**：状态项、事件项、结果项、Probe 项；另一轨是**人审标签**：建议是否越界、是否过度归因、是否有沉迷诱导、是否需要人工转介。根据《生成式人工智能服务管理暂行办法》，数据标注应制定清晰、具体、可操作的规则，并开展质量评估与抽样核验。这一点可以直接作为内部标注治理制度的法规依据。 29

风险方面，需要把“技术风险、伦理风险、法律风险、市场风险、可解释性风险”放在同一张表中管理。

风险	表现	缓解措施
技术风险	过拟合、路径校准差、关系图噪声大	先用可解释主干；保留不确定性输出；多路径而非单点结论
伦理风险	诱导依赖、替代社会关系、过度情绪卷入	强化边界提示；限制拟人化；长时使用提醒；转介机制

风险	表现	缓解措施
法律风险	过度收集、敏感信息滥用、标识缺失	最小化采集、单独同意、PIPIA、显隐式标识、日志审计
市场风险	概念过大、价值不聚焦	从职场关系与团队变动切入，先解决具体问题
可解释性风险	用户不信模型、企业无法采购	保留 Edge Vector、Edge Shift、Evidence Trace、Path Conditions
竞争风险	通用 LLM 快速复制外观	用理论、数据闭环、评估体系与合规能力形成壁垒

其中，法律与伦理项特别重要。中国监管已经明确把生成式 AI 标识、深度合成备案、个人信息保护、拟人化互动边界作为重点治理对象；2025 年已有对未落实标识要求的应用进行集中查处，2026 年又启动了“清朗·整治 AI 应用乱象”专项行动，覆盖备案、安全围栏、标识、数据投毒、隐私侵害等问题。因此，Edging GPT 必须从 Day 1 就把**标识、最小化、留痕、可退出、人工复核与风险预案**作为系统级能力，而不是法务补丁。³⁰

立项报告附录

项目名称：Edging GPT 第三版本
项目性质：理论驱动型 AI 平台研发项目
项目周期：36 个月
建议立项等级：公司级创新项目
建议研发形态：先 SaaS MVP，后企业版与私有化

项目背景。当前通用 LLM 已具备强表达能力，但在多轮关系判断、环境校准和低风险主动采样上仍然缺乏统一目标函数。另一方面，企业端 AI 采用率上升，但多数项目尚未完成从试点到规模化的跨越，说明单纯“加一个聊天框”并不足以形成业务价值。与此同时，中国对个人信息、生成式 AI 标识、深度合成和拟人化互动的监管已从原则性要求进入细则与执法阶段。Edging GPT 因此需要以“可解释变化建模”切入，而非以泛情绪陪伴切入。¹

项目目标。在 36 个月内形成一套可落地的 Edge 理论与系统方案。理论目标是建立 Edge、Edgefield、Edge Shift、Edge Trajectory、Edge Map、Information Potential 等核心术语与数学表示；技术目标是实现基于状态空间模型的 Edgefield 演变引擎、基于 EIG 的主动提问策略、多路径仿真与 Edge Probe 规划器；产品目标是上线个人版 MVP 与至少两个企业试点场景；经营目标是形成“订阅 + 企业版 + 咨询”的三层收入模型。

项目范围。范围内包括：理论白皮书、问卷与对话数据采样体系、状态估计与仿真引擎、GPT 对话层、可视化报告、标注与评估后台、合规与审计模块。范围外包括：高风险医疗、金融、法律专业意见；未授权第三方画像；默认接入位置与通讯录等高隐私数据；面向未成年人的亲密陪伴场景。对于跨境部署、行业私有语料接入、企业内部系统对接，本立项作为开放选项处理。³¹

预期成果。第一类成果是理论资产：形成《Edging：变化计算理论》白皮书 V1、术语标准与数据字典。第二类成果是技术资产：完成 Edge Engine、Question Policy、Simulation Engine、Edge Map 模块。第三类成果是产品资产：完成个人版 MVP、管理者版试点、企业版仪表盘。第四类成果是治理资产：完成隐私影响评估模板、模型输出审计规范、标识与日志制度。第五类成果是商业资产：完成至少 2 个付费试点、1 个私有化 PoC、1 套咨询方法包。

初步技术方案。路线建议为：以状态空间模型和贝叶斯滤波作为主干，先实现稳定、可解释、可在线更新的 Edgefield 演变引擎；用规则 + 信息增益函数实现主动提问；用蒙特卡洛分支模拟实现多路径预测；用动态图模块增强关系网络；在积累足够样本后，再考虑因果 uplift 与强化学习选问策略。该路线与状态空间、动态图、

因果与主动特征获取相关研究一致，也与 NIST 对生成式 AI 风险治理的“分角色、分阶段、分生命周期”原则相容。³²

时间表与里程碑。

M1（第 2 月）：术语冻结与 Initial Edge 问卷定稿。
M2（第 4 月）：状态估计主干与基础 GPT 交互打通。
M3（第 6 月）：个人版 MVP 上线，完成首轮离线回测。
M4（第 9 月）：环境侧写与关系侧写上线，形成 Edge Trajectory 报告。
M5（第 12 月）：完成第一轮在线 A/B 测试，形成企业试点方案。
M6（第 18 月）：Edge Map 与动态图增强版上线。
M7（第 24 月）：因果评估与管理者仪表盘 PoC。
M8（第 36 月）：企业版、私有化与行业模板成熟交付。

预算估算。建议采用“基础预算 + 弹性预算”双层审批：基础预算覆盖研发、人审、合规、安全与基础云成本；弹性预算覆盖大模型 API 峰值、企业试点、行业顾问与市场验证。立项时建议先批第一阶段预算，第二阶段以前一阶段的指标达成为放款条件。预算区间可参考前表：6 个月 180-260 万元，18 个月累计约 600-900 万元，36 个月累计约 1500-2400 万元。该估算为开放区间，受团队地点、模型采购与私有化需求影响较大。

团队组织。建议采用“产品—理论—算法—应用—治理”五线结构。项目经理对里程碑负责，理论负责人对术语与指标负责，算法负责人对状态建模与评估负责，应用负责人对 GPT 交互与前后端交付负责，治理负责人对法务、隐私与安全审查负责。企业版需要额外配置行业顾问与解决方案经理。

风险评估与对策。立项通过的前提，不是“模型能说得人像人”，而是“系统能否在低风险条件下形成数据闭环、可解释输出和精简采样”。若 6 个月后仍无法在离线回测中证明“主动采样优于静态问卷”、或无法把高风险建议率降到预设阈值，就应触发阶段性收缩。若企业试点证明 Edge Map 的价值不足，则应把产品聚焦回个人职场场景，而不是硬推组织分析。

合规计划。按中国法域上线时，必须执行：个人信息最小化与目的限定；敏感信息单独同意；自动化决策与重大影响处理的影响评估；生成内容显式/隐式标识；按需备案与安全评估；输入与使用记录保护；拟人化互动提示、退出机制与使用时长提醒。若国际化，需额外映射 GDPR 与 EU AI Act 的透明度、数据主体权利与高风险分类要求。³³

未指定项与假设。本报告对以下内容作开放假设：预算上限按 1500-2400 万元区间估算；核心团队按 8-14 FTE 递增；默认可接入的数据源为问卷、对话、用户手动输入关系与公开事件，不默认接入位置、通讯录、第三方社交；默认部署法域为中国大陆，跨境传输视为后续立项子项；模型底座可采用商用 API 或私有模型，最终方案取决于交付对象对数据驻留和价格的要求。

下一步可交付物

第一，交付 **《Edging：变化计算理论》白皮书 V1 提纲 + 术语字典**。内容包括核心公理、数学表示、Edge/Edgefield/Edge Shift/Edge Probe 的正式定义，以及 64 维基向量的命名规范。这是整个项目的理论锚点。

第二，交付 **MVP 技术规格包**。内容包括 Edge Test 题库 V1、数据字典、状态更新接口、Question Policy 规则、Simulation Engine 输入输出协议、评估指标计算脚本。这是研发落地的最小技术边界。

第三，交付 **正式立项材料套件**。内容包括项目章程、阶段预算、团队编制、风险清单、合规清单、试点场景方案与里程碑甘特图，用于内部评审与资源申请。

- 1 26 <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>
<https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>
- 2 https://ocw.mit.edu/courses/15-871-introduction-to-system-dynamics-fall-2013/b950bd7b4f565b7b19145fb16bd55c8e_MIT15_871F13_ass3.pdf
https://ocw.mit.edu/courses/15-871-introduction-to-system-dynamics-fall-2013/b950bd7b4f565b7b19145fb16bd55c8e_MIT15_871F13_ass3.pdf
- 3 7 15 32 <https://www2.econ.osaka-u.ac.jp/~tanizaki/class/kalman-e/kalman-e.pdf>
<https://www2.econ.osaka-u.ac.jp/~tanizaki/class/kalman-e/kalman-e.pdf>
- 4 5 8 <https://crad.ict.ac.cn/fileJSJYJFZ/journal/article/jsjyjfz/HTML/2022-01-47.shtml>
<https://crad.ict.ac.cn/fileJSJYJFZ/journal/article/jsjyjfz/HTML/2022-01-47.shtml>
- 6 10 11 23 28 <https://www.jmlr.org/papers/volume26/23-1635/23-1635.pdf>
<https://www.jmlr.org/papers/volume26/23-1635/23-1635.pdf>
- 9 13 22 27 31 33 https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm
https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm
- 12 <https://cje.ustb.edu.cn/cn/article/pdf/preview/10.13374/j.issn2095-9389.2021.07.04.002.pdf>
<https://cje.ustb.edu.cn/cn/article/pdf/preview/10.13374/j.issn2095-9389.2021.07.04.002.pdf>
- 14 https://www.spp.gov.cn/spp/tt/202503/t20250314_690508.shtml
https://www.spp.gov.cn/spp/tt/202503/t20250314_690508.shtml
- 16 17 <https://arxiv.org/abs/1601.00670>
<https://arxiv.org/abs/1601.00670>
- 18 <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf>
<https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf>
- 19 <https://research.google/pubs/ask-the-right-questions-active-question-reformulation-with-reinforcement-learning/>
<https://research.google/pubs/ask-the-right-questions-active-question-reformulation-with-reinforcement-learning/>
- 20 <https://arxiv.org/abs/2508.21184>
<https://arxiv.org/abs/2508.21184>
- 21 24 https://www.cac.gov.cn/2026-04/10/c_1777558395078289.htm
https://www.cac.gov.cn/2026-04/10/c_1777558395078289.htm
- 25 <https://link.springer.com/article/10.1007/s11704-024-3853-2>
<https://link.springer.com/article/10.1007/s11704-024-3853-2>
- 29 https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm
https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm
- 30 https://www.cac.gov.cn/2025-11/25/c_1765795550841819.htm
https://www.cac.gov.cn/2025-11/25/c_1765795550841819.htm